

Dopady obmedzenia mobility na šírenie vírusu Covid-19

Na základe dostupných dát o incidencií a prevalencii ochorenia COVID-19 v Slovenskej republike a najlepších dostupných modelov predikujeme, že opatreniami postupne zavedenými do 16.3.2020 sme výrazne pomohli spomaliť šírenie ochorenia. Napriek tomu očakávame, že bez targetovaných opatrení na rizikové skupiny (vek, lokalita) bude prevalencia ochorenia na vrchole v 110tý deň od 15.3 (s peakom 10%), čo je nad rámec kapacít Slovenského systému. Ďalšie opatrenia sú preto na zvážení, primárne v problémových oblastiach a pre rizikovú populáciu. Presnosť analýz sa dá zlepšiť údajmi od mobilných operátorov a domodelovaním / odhadnutím R_0 pre MRK. Je nevyhnutné spomenúť, že model ovplyvňuje aj mnoho iných premenných, ktoré budú zrejmé v čase, preto IZP pripraví druhú verziu modelu 23.3.2020 s aktualizovanými údajmi a doplnenou metodikou o MRK.

Úvod

Nakoľko nová variácia koronavírusu, COVID-19, má inkubačnú dobu dĺžky 2-14 dní, symptómy a nedostatok testovacích kapacít po celom svete limitujú rozoznávajúce reálneho počtu prípadov. Tento model je snahou o predikciu incidencií a prevalencií COVID-19 na SR na základe dostupných dát a pod vplyvom opatrení vlády platných 16.3.2020. Cieľom je modelovať situáciu na základe existujúcich epidemiologických modelov za účelom predpovedania potreby starostlivosti a testovania pre individuálne obce na základe zvolených parametrov. Materiál bol pripravený pre účely ústredného krízového štábu, nemá teda ambíciu poskytnúť detailný sumár dostupnej literatúry či štúdií, ale prezentovať jeden funkčný model s jeho limitáciami.

Túto metódu sme zvolili, nakoľko sme chceli framework, kde vieme modelovať šírenie nákazy v geografickom priestore, aby sme vedeli skúmať dopad zníženia mobility alebo úplnej karantény určitého miesta. Model je dostatočne jednoduchý, aby bolo možné pridávať ďalšie scenáre, napríklad absolútne zníženie mobility pre seniorov, vyššia transmisia pre marginalizované rómske komunity (MRK) alebo postupné zvyšovanie mobility obyvateľstva. Výhodou tiež je, že vidíme v čase ako predikovaná úroveň prevalence stúpa pre každú obec, takže aj bez detekovaných prípadov máme odhad, že v nich dochádza k pravdepodobnému nárastu incidence a je tam treba zakročiť vrátane širšieho testovania danej populácie. Na rozdiel od napríklad Read et al (2020) predpokladáme, menšiu úroveň mobility (kvôli rurálnosti Slovenska v porovnaní s Wuhanom), no vyšší priemerný počet ľudí nakazených jedným pacientom. Snahou bolo zohľadniť špecifiká slovenskej situácie, ako aj terajších opatrení na kontrolu rozširovania nákazy. Premenné boli podrobené analýze senzitivity, pričom do týždňa pripravíme druhú verziu predikcie, kde využijeme údaje od mobilných operátorov, ako aj predpoklady z čerstvo publikovanej štúdie z Imperial Collegeu (Ferguson et al, 2020) ohľadne dopadov jednotlivých intervencií.

Tento model je limitovaný predpokladaním incidence na základe odhadovaných štatistík a zjednodušovaním pohybu osôb na predpokladanú úroveň. Pre detailné predikcie potrebujeme detailné dáta o pohybe osôb na území SR od mobilných operátorov, ako aj pre targetovanie najohrozenejších skupín. Ako ukazujú prípady menších krajín úspešných v reagovaní na pandémiu, cielené kontroly a vyšetrovanie ohrozených skupín viedlo k zníženiu rastu incidence aj fatality spojených s ochorením – a to aj bez mimoriadne vysokých úrovní testovania.

Prehľad použitej metodiky

1. Analýza obsahuje simuláciu prenosu vírusu Covid-19 po Slovensku na základe migračných tokov medzi všetkými slovenskými obcami, a to podľa modelu na základe článku z časopisu Nature (Wesolowski et al, 2017 a Yeghikyan, 2020 a migračného toku od IFP). V rámci analýz sme vyskúšali viaceré modely, ako napríklad Kucharski et al (2020), avšak vybraný model bol v rámci dostupných a overených modelov najlepší zohľadňujúci flexibilitu či obsahujúce premenné.
2. Simulácia berie situáciu ohľadom počtu nakazených z 15.3.2020 ako deň nula, po ktorom progres nákazy pokračuje.
3. Model simuluje postup vírusu vždy v rámci jedného mesta, ktoré je rozdelené na políčka o veľkosti 250x250 metrov, medzi ktorými sa ľudia presúvajú [podľa odporúčaní Yeghikyan, 2020). Aplikovali sme model na predikciu šírenie COVID-19 na Slovensku na leveli obce.

4. Model používa parametre vírusu popisujúce rýchlosť šírenia na základe odhadov z literatúry, je však skôr popisom dynamiky rastu infikovaných ako presnou predikciou počtu nakazených. V súčasnej dobe takmer na dennej báze vychádzajú štúdie predikujúce R_0 vírusu, neexistuje preto ešte jedna robustná predikcia, resp. model (pozri napr. Liu et al (2020, 2020a).
5. Model na základe cestovania medzi políčkami mesta charakterizuje rýchlosť infikovania ďalšieho obyvateľstva. Je možné modelovať vplyv obmedzení v cestovaní a v sociálnom kontakte alebo úplnú karanténu niektorého bodu (napríklad uzatvorenie centra mesta). Model je preto možné využiť v Slovenskom kontexte pre štúdium šírenia vírusu medzi slovenskými obcami.
6. Intenzita vzťahov medzi obcami je špecifikovaná skutočnými historickými pohybmi obyvateľstva medzi všetkými kombináciami obcí na Slovensku.
7. Model analyzuje 3 vybrané scenáre:
 - a. Šírenie nákazy pri 100% mobilite populácie (oproti štandardnému toku obyvateľstva z dát IFP; tzv. „vysoká mobilita“; inak povedané, ľudia migrujú ako keby sa nič výnimočné nedialo)
 - b. Šírenie nákazy pri 40% mobilite populácie (oproti štandardnému toku obyvateľstva z dát IFP; tzv. „stredná mobilita“, toto číslo je odborný odhad)
 - c. Šírenie nákazy pri 20% mobilite populácie (oproti štandardnému toku obyvateľstva z dát IFP; tzv. „nízka mobilita“ – čiže stav predikovaný od 16.3.2020, číslo je odborný odhad)
8. Momentálne model vychádza zo štandardnej mobility populácie na základe dát Inštitútu finančnej politiky. S presnejšími geolokačnými dátami od mobilných operátorov, je možné model výrazne spresniť, čiže 100, 40, 20% by boli nahradené presnými údajmi pohybu obyvateľstva a modelovať je možné migrácie obyvateľov v rámci miest a obcí.

Použitý model šírenia vírusu ma 2 hlavné parametre, alfa a R_0 , a požaduje maticu mobility medzi lokalitami.

1. Alfa je premenná ukazujúca level mobility populácie. Jedna reprezentuje úplnú mobilitu (štandardná migračné správanie, množstvo presunov medzi obcami a plný sociálny kontakt) a nula reprezentuje úplné zastavenie mobility medzi mestami.
2. R_0 (basic reproduction number) reprezentuje priemerný počet ľudí, ktorí sú nakazení jednou infikovanou osobou v infikovateľnej populácii. Podľa doterajších odhadov je to 1.4–3.9 pre nový koronavírus (Li et al., 2020; Riou and Althaus, 2020; Liu et al., 2020), ale dosahujú v prípade nekontrolovaného rastu hodnoty až 14,8 (Rocklov et al., 2020). Simulácia R_0 v rámci uzatvoreného prostredia lode Diamond Princess bola v mediáne 95% confidence intervalu podľa Zhang (2020) na úrovni $R_0=2,26$. V simulácii IZP je použitá najvyššia horná hranica odhadu reprodukčného čísla – 4. Simulácie je možné riešiť aj s inými parametrami, kde dynamika peakov zostane rovnaká, ale odlišovať sa bude ich vrchol a rozloženie. Analýza v tejto verzii nediferencuje R_0 pre MRK, pričom z odhadu vývoja iných prenosných ochorení aj celkového socio-ekonomického pozadia je vysoko pravdepodobné, že MRK budú mať vyššie hodnoty R_0 . Túto hypotézu zapracujeme do druhej verzie modelu.
3. Matica mobility je matica presunov obyvateľstva medzi obcami na základe reálnych historických údajov.

Popis premenných v simulácii:

N – populácia v danej obci.

S – počet tých, ktorí sa môžu nakaziť (v simulácii všetci, ktorí nikdy nemali vírus)

I – počet infikovaných

R – počet vyliečených (v simulácii sa nemôžu nakaziť znovu)

x = I / N – pomer infikovaných v obci

y = S / N – pomer tých, ktorí sa ešte môžu nakaziť (pomer „susceptible“)

m(j,k) – mobilita z obce j do obce

R0 – „basic reproduction number“, priemerný počet ľudí, ktorí sú nakazení infikovanou osobou.

Iteračné kroky simulácie:

$$\begin{aligned}S_{j,t+1} &= S_{j,t} - \frac{\beta_{j,t} S_{j,t} I_{j,t}}{N_j} - \frac{\alpha S_{j,t} \sum_k m_{j,k}^t x_{k,t} \beta_{k,t}}{N_j + \sum_k m_{j,k}^t} \\I_{j,t+1} &= I_{j,t} + \frac{\beta_{j,t} S_{j,t} I_{j,t}}{N_j} + \frac{\alpha S_{j,t} \sum_k m_{j,k}^t x_{k,t} \beta_{k,t}}{N_j + \sum_k m_{j,k}^t} - \gamma I_{j,t} \\R_{j,t+1} &= R_{j,t} + \gamma I_{j,t},\end{aligned}$$

Výhody modelu

- Komplexný model, ktorý berie do úvahy geografiu, predikovateľný na dni
- Je možné zakomponovať migračné vzorce v rámci SR
- Parameter mobility umožňuje simulovať scenáre obmedzenia cestovaní a sociálneho kontaktu populácie; upravením migračnej matice možné simulovať dopad uzavretia obce.
- Jednoduchosť modelu umožňuje testovať ďalšie hypotézy, ako napríklad postupné zvyšovanie mobility v čase a dopady opatrenia na incidenciu


Limitácie súčasného modelu

- Matica pohybu osôb nezahŕňa pohyb zo zahraničia (je ho možné pridať, kde zahraničné mestá alebo krajiny budú ďalšie lokality)
- Model neráta s neštandardným správaním, čiže vyšším R0 určitých skupín obyvateľstva, ako napr. v prípade marginalizovaných rómskych komunít¹
- Mobilitu predikujeme na základe odborných (a agregovaných) odhadov, bez informácií od mobilných operátorov nevieme presne určiť migračné toky
- V súčasnej dobe máme príliš malý počet pacientov, aby sme vedeli vykonať presnejšiu predikciu kapacitného modelu

Výsledky simulácie


Tento model je výsledkom 100 simulácií a je iniciovaný podľa momentálneho stavu nákazy v SR (prípady, ktoré boli odhalené k 15.3.2020 – spolu 61 prípadov, z čoho 27 v Bratislave).

¹ V druhej analýze bude táto informácia tiež zohľadnená v modeli s použitím údajov z Atlasu rómskych komunít a konzultácií s epidemiológom.



Graf 1: Všetky vs. detekované prípady nákazy

Keďže identifikované prípady pravdepodobne výrazne podhodnocujú reálny počet prípadov, iniciačný počet vyplýva z identifikovaných prípadov vynásobených odhadovaným nárastom počtu týchto prípadov počas inkubačnej doby, ktorá bol odhadnutá na úrovni 6 dní (pri 95% CI – 4,5 až 5,8 dní podľa Lauer et al, 2020). Ako je možné vidieť na grafe nižšie z aktuálnych údajov je tento koeficient na úrovni 6.




Graf 2: Nárast identifikovaných prípadov COVID-19 v SR

Variácia mobility obyvateľstva

Cieľom modelovania bolo zobraziť peaky, čiže body s najvyššou prevalenciou v jeden deň, aby sa tieto hodnoty dali porovnať s existujúcou kapacitou invazívnej ventilačnej techniky, resp. JIS/ARO kapacít. Grafy nezobrazujú preto celkový počet infikovaných, ale aktuálne hodnoty daných dní.


- **Pri vysokej mobilite obyvateľstva** (žiadne alebo takmer žiadne obmedzenia) nastáva peak infekcie už 26 dní od začiatku simulácie, kedy sa nachádzalo na Slovensku 61 prípadov, z toho väčšina v Bratislave. Pri vrchole infekcie je nakazených až 45 % populácie. Po 50 dňoch od začiatku nákazy pomer infikovaných osôb klesá pod 10 percent populácie. Podobný priebeh v súčasnosti pravdepodobne prebieha v Taliansku a Španielsku, o čom svedčí extrémny nárast pacientov na dennej báze, ako aj spojená vysoká úroveň mortality (ECDC, 2020).
- **Pri strednej mobilite obyvateľstva** (stredne prísne obmedzenia) je vrchol infekcie nižší (25 percent populácie) a nastáva neskôr (60. deň), keďže nákaza je viac rozložená v čase. Choroba má v tomto prípade dlhší celkový priebeh, a tak pomer infikovaných osôb klesá pod 10 percent až v 75. deň. Na základe odborného odhadu a aproximácie štúdie Ferguson et al. (2020) sa jednalo o opatrenia, ktoré boli platné na Slovensku k 16.3.2020.
- **Pri výrazných obmedzeniach mobility** (uzatvorené školy, povinná karanténa okrem nevyhnutných nákupov, atď.) je efekt nižšieho peaku a pomalšieho nástupu choroby najvýraznejší. Aj keď celkový pomer nakazených je stále na vrchole 10 percent, táto situácia nastáva až po 110 dňoch od začiatku simulácie, a tak predstavuje výrazne nižšiu záťaž pre zdravotnícky systém. Kvôli postupnému priebehu vírusu sa pomer infikovaných osôb znižuje pod 5 percent po vyše 150 dňoch. Toto je situácia (vyznačená v grafoch zelenou), ktorá najbližšie korešponduje so súčasnými podmienkami na SR, platnými k 16.3.2020.



Graf 3: Peak infekcie podľa mobility obyvateľstva

(červená – vysoká mobilita; oranžová – stredná mobilita; zelená – nízka mobilita predpokladaná po 16.3.2020)

Nasledujúci graf ukazuje počet nových nákaz v čase podľa mobility obyvateľstva. Vrcholy nákaz sú tu zreteľnejšie – napríklad pri plnej mobilite sa väčšina obyvateľov nakazí do 20 dní od začiatku simulácie a počet následne klesá, keďže v simulácii tí, ktorí už vírus mali, by ho v modeli nemali dostať znova.



Graf 4: Nárast infekcie podľa mobility obyvateľstva, absolútny počet

(červená – vysoká mobilita; oranžová – stredná mobilita; zelená – nízka mobilita predpokladaná po 16.3.2020)

Celkový počet nakazených ako výstup z modelu je zobrazený v Tabulke 1 nižšie pre vybrané dni.

Počet dní od nákazy	Vysoká mobilita, Počet infikovaných	Stredná mobilita, Počet infikovaných	Nízka mobilita, Počet infikovaných
10	42,696	2,336	759
20	918,523	28,768	2,428
30	2,352,862	224,702	5,757
40	1,337,881	759,751	18,728
50	509,381	1,359,575	44,042
60	182,973	1,302,884	86,709
80	22,842	409,275	304,996
100	2,843	84,462	537,391
150	16	1,827	251,282
200	0	47	31,488

Tabuľka 1: Prevalencia (celková) v čase podľa troch scenárov mobility

*V/A/L – vyliečení, asymptomatickí, v procese liečby; pre prezentatívne účely sme použili agregát

Prečo model predikuje tak vysoké úrovne infikovaných a diagnostikovaných pacientov?

Ako ukazujú mnohé štúdie, napríklad Verity et al (2020), Ferguson et al (2020) alebo Niehus et al (2020), reálny počet nakazených je násobne vyšší než množstvo diagnostikovaných pacientov v akomkoľvek systéme. Podľa dát z Číny takmer **40-50% infekcií neboli identifikované ako prípady práve preto že nevykazovali symptómy**. (Niehus et al, 2020). Tento rozdiel vzniká z troch hlavných dôvodov – limitovaných kapacít zdravotníckych systémov testovať celú populáciu, dlhej inkubačnej doby a z dôvodu, že v štyroch z piatich prípadov sú buď slabé alebo aj neprejavované symptómy. Je však potrebné zohľadňovať týchto „infikovaných-nediagnostikovaných,“ nakoľko môže ísť o tichých šíriteľov vírusu v rámci rizikovej populácie. Inak povedané, model IZP predikuje očakávanú reálnu prevalenciu ochorenia, pričom podobne ako iné krajiny popísané v štúdiách, v realite detekujeme testami len časť z tejto množiny.

Prípád Južnej Kórey a veľmi vysokého množstva testov ukazuje (ale aj pokročilého zdravotníckeho systému), ako nízka je reálna fatalita (0,8%) za predpokladu že poznáme počty bližšie reálnym číslam nakazených ľudí. To však nie je prípad takmer v žiadnej inej krajine a krajiny s podobne nízkou fatalitou majú skôr menší počet detekovaných nákaz. Posledná štúdia, ktorá sumarizovala pomery hospitalizovaných až po IFR (infection fatality ratio), bola publikovaná včera (16.3.2020; Ferguson et al., 2020) a okrem spomínaných 40-50% detekovaných pacientov sumarizuje nasledovné hodnoty dopytu po ústavnej starostlivosti:

Veková skupina	% symptomatických prípadov vyžadujúcich hospitalizáciu	% hospitalizovaných vyžadujúcich akútnu starostlivosť	IFR (infection fatality ratio)	
0 - 9	0,10%	5%	5%	0,00%
10 - 19	0,30%	5%	5%	0,01%
20 - 29	1,20%	5%	5%	0,03%
30 - 39	3,20%	5%	5%	0,08%
40 - 49	4,90%	6,30%	6,30%	0,15%
50 - 59	10,20%	12,20%	12,20%	0,60%
60 - 69	16,60%	27,40%	27,40%	2,20%
70 - 79	24,30%	43,20%	43,20%	5,10%
80+	27,30%	70,90%	70,90%	9,30%

Tabuľka 2: Publikované pomery pacientov vyžadujúcich hospitalizáciu, akútnu starostlivosť a IFR

Zdroj: Ferguson et al (2020) a Verity et al (2020)

Tieto hodnoty vychádzajú z regionálnych špecifik, prístupu k testovaniu či organizácie starostlivosti. Ich aplikácia na náš systém je preto len hrubý odhad. Na Slovensku ešte totiž nemáme dostatočný počet pacientov, aby sme vedeli modelovať aj presnú vekovú štruktúru, a tým lepšie asimilovať model. Ak však rátame súčasnú vekovú distribúciu, tak očakávame, že 7,43% symptomatických pacientov bude vyžadovať hospitalizáciu a 13,75% z nich bude vyžadovať akútnu starostlivosť. Na základe R03 výkazu NCZI (Ročný výkaz o zdravotníckej technike), máme k dispozícii takmer 450 ventilátorov, ktoré sa dajú

použiť na invazívnu ventiláciu pacientov. Štátne hmotné rezervy v súčasnej dobe navyšujú tento stav o minimálne 100 kusov. Kapacitne preto rátame, že bez obmedzení² bude náš systém schopný zvládnuť 550 ventilovaných pacientov s COVID-19. Je preto zrejmé, že obmedzenia výrazne prispeli k zrovnaniu dopytu po starostlivosti, ale v prípade potvrdenia pesimistických predikcií IZP bude potrebné do 60 dní ďalšie kapacity, alebo prísnejšie opatrenia.

Nemecké zdravotníctvo, ako jedno z najlepších opatrení, preto objednalo do rezervy 10 000 prístrojov, Taliansko prikázalo lokálnemu výrobcovi presmerovať celú produkciu (500 kusov mesačne) na účely Talianskych nemocníc (Buck and Ghiglione, 2020) a zavádzajú prísnejšie opatrenia.

Počet dní od nákazy	Prevalencia	Symptomatickí pacienti	Hospitalizácie	Vyžadujúci intenzívnu starostlivosť
10	759	455	34	5
20	2 428	1 457	108	15
30	5 757	3 454	257	35
40	18 728	11 237	835	115
50	44 042	26 425	1 964	270
60	86 709	52 025	3 866	532
80	304 996	182 998	13 598	1 870
100	537 391	322 435	23 959	3 294
150	251 282	150 769	11 203	1 540
200	31 488	18 893	1 404	193

Tabuľka 3: Očakávaný dopyt po ústavnej starostlivosti v prípade nízkej mobility

Komentár

Základným výstupom tejto analýzy je porovnanie vplyvu opatrení a obmedzenia mobility populácie na celkový priebeh a vývoj epidémie COVID-19. Môžeme potvrdiť, že opatrenia po 16.3.2020 pozitívne ovplyvnia celkovú prevalenciu tohto ochorenia a podľa simulácie nepresiahne peak prevalence 10% všetkých prípadov. Po prerátaní na potrebu hospitalizácií je to zvláduteľná hodnota (pri postupnom doplnení kapacít). K tejto situácii by však došlo v prípade, že zavedené opatrenia zostanú v platnosti najbližšie 3 až 4 mesiace (peak sa dosiahne po 110 dňoch) a v závislosti od miery prevalence, ktorú je potrebné dosiahnuť na zabezpečenie kolektívnej imunity. Scenár prísnych opatrení limitujúcich mobilitu v krajine je kvôli vplyvu na bežný život a ekonomiku krajiny nepravdepodobný, a preto je potrebné zabezpečiť aj iné formy opatrení, ktoré budú minimalizovať extrémne negatívne ekonomické efekty, spojené s touto situáciou.

² Abstrahujeme od iných limitácií, karantén personálu a pod. Ide len o priame porovnanie technického maxima kapacít invazívnej ventilácie.


Náš scenár je konzervatívny (pesimistický), odhaduje najhoršie možné scenáre, pričom uvažuje s pomerne vysokou mierou reprodukcie ($RO = 4^3$) a pomerne miernymi dopadmi opatrení na mobilitu populácie (100%, 40% a 20% pre jednotlivé scenáre). Je vysoko pravdepodobné, že silnejšie opatrenia by viedli k ešte väčšiemu splošteniu epidemiologickej krivky. Kvôli potrebnému trvaniu týchto opatrení pred dosiahnutím peaku preto považujeme cielené opatrenia za efektívnejšie riešenie. Na druhej strane nediferencujeme MRK či fakt, že už dnes môžeme mať neidentifikované ohniská nákazy. Preto pripravíme druhú, metodologicky robustnejšiu verziu modelu, ktorú budeme na dvojďňovej báze aktualizovať.

Nakoľko používame pri simuláciách maticu pohybu osôb medzi obcami a každý deň je prepočítaný na všetky obce, disponujeme po ukončení simulácie údajmi o šírení vírusu v čase pre každú z nich. To nám umožňuje modelovať dopady na jednotlivé regióny a prijať rozličné optimálne opatrenia na zamedzenie pohybu osôb, za účelom nepresýtenia kapacít zdravotníctva – tzv. „flattening the curve.“ Na lepšie predikcie by sme však potrebovali údaje od mobilných operátorov s exaktným pohybom obyvateľstva a s identifikáciou ľudí, ktorí boli v rizikových oblastiach (severné Taliansko napríklad). Tieto údaje boli vyžiadané výborom MZ SR a prisľúbené ústredným krízovým štábom v pondelok 16.3.2020.

Po ich obdržaní dokážeme vytvoriť targetované opatrenia na najviac ohrozené regióny, obce či skupiny obyvateľstva, podobne ako tomu je v Nemecku či iných krajinách.

Najlepší predikčný model sa ukáže až empiricky, po prekonaní tejto pandémie. Odhadujeme, že ideálnou cestou môže byť kombinácia viacerých opatrení, napr. cielená karanténa pre rizikovú populáciu a rizikové lokality, zabezpečenie domácej starostlivosti pre väčšinu pacientov s ľahkým a miernym priebehom, testovanie len v prípade jasných príznakov alebo dimenzované pre rizikové skupiny a podobne. Štúdia Imperial Collegu (Ferguson et al., 2020) sa pokúsila empiricky dopočítať dopady jednotlivých opatrení, ako zobrazuje nasledovný graf, avšak ich efektivita bude závisieť od disciplíny obyvateľstva, pokročilosti zdravotníckeho systému a ďalších faktorov. Z tejto analýzy je však zrejmé, že Slovensko zaviedlo takmer všetky mitigačné či supresívne opatrenia, ktoré sú k dispozícii, čo malo pozitívny vplyv na spomalenie šírenia vírusu.

³ To znamená, že jeden pacient je schopný počas svojho ochorenia nakaziť 4 ďalších pacientov.



Graf 5: Dopady zavedenie rozličných opatrení na NHS kapacity kritickej starostlivosti (Ferguson et al, 2020)

Modely úspešnej reakcie

Úspešné reakcie globálnych vlád na by sa dali rozdeliť do troch skupín: Čína, Južná Kórea a Taiwan.

Čínska voľba bola minimalizácia rozširovania nákazy od istého bodu absolútnym odstihnutím mesta a provincie od zvyšku sveta (model dokáže situáciu simulovať „vypnutím“ migrácie medzi touto lokalitou a zvyškom). Táto forma môže byť inšpiráciou z hľadiska výrazného zníženia pokračujúcej nákazy, no má výrazný vplyv na bežný živo aj level ekonomickej aktivity v štáte. O podobnú úroveň oddelenia od zvyšku sveta sa v súčasnosti pokúša severné Taliansko.

Juhokórejský model bol založený na výrazne vyššej kapacite pre testovanie než sme schopní dosiahnuť v tejto dobe. Dodnes bolo uskutočnených viac než štvrt milióna testov v rámci celej krajiny, čo je druhý najvyšší počet po čínskom Wuhane. Kórejský model bol tiež výnimočný viacerými pacientami, takzvanými „super-šíriteľmi,“ ktorí výrazne nad priemerom rozšírili infekciu v populácii.

V Taiwane boli schopní zachovať mimoriadne nízky počet nakazených ľudí i napriek proximite k Číne. Krajina neblokuje pohyb v rámci vlastného územia do takej miery ako Čína, tiež nedisponuje takým počtom testovaných ako Južná Kórea. Taiwanský úspech vychádza z dobrého manažmentu potenciálnych a nakazených pacientov. Tri kľúčové body sú:

- Samo-ohlasovanie histórie cestovania a symptómov povinný u všetkých prichádzajúcich zo zahraničia cez automatizovanú aplikáciu.
- Detailný tracking prípadov (geograficky aj historicky) – vďaka špecifickej aplikácii sledujúcej pohyb.

- Dobrý manažment osvetu a informovania verejnosti – dostupnosť rúšok, komunikácia o príznakoch a prevencii cez vyhradené sloty v televízii.

Práve na základe skúseností z Taiwanu chceme využiť detailné dáta od mobilných operátorov na špecifické kontrolovanie, ako aj oslovanie rizikových skupín obyvateľstva. Prípad Taiwanu ukazuje, že situáciu je možné dostať pod kontrolu v prípade komplexného manažmentu pacienta (Wang et al, 2020).

Záver

Pre efektívnu schopnosť reakcie na COVID-19 je potrebné predikovať potrebu starostlivosti v jednotlivých geografických oblastiach a čo najviac minimalizovať mobilitu v krajine. Ďalšie možné opatrenia do budúcnosti budú musieť byť analyzované z pohľadu možných benefitov a rizík. Presnosť modelov a analýz, ak aj schopnosť štátu reagovať, je možné zlepšiť presnými údajmi od mobilných operátorov, na základe ktorých budeme schopní exaktne dopočítať predikcie nových nákaz, ako aj rizikové oblasti v krajine. Analýza abstrahovala od nie vždy štandardného správania MRK, čo bude upravené v ďalšej verzii.

Potlačenie epidémie prostredníctvom sociálneho oddeľovania je najlepšia možná forma reakcie na túto krízu a ako ukazuje náš model, znížovanie mobility a šírenia nákazy bude kľúčové pre limitovanie jeho rozsahu do najrizikovejších skupín. V dlhodobom ohľade poskytne dost času zdravotníckemu systému reagovať na ochorenia najkritickejších skupín do času, keď sa u populácie vytvorí kolektívna imunita.

IZP pripraví druhú verziu modelu do pondelka 23.3.2020 a zapracuje údaje o presnom pohybe obyvateľstva, aby sa ciele politiky a akcie dokázali čím skôr a adresne aplikovať. Kompletný model zverejníme na webe IZP pre ďalšiu replikáciu, pripomienky a vylepšenie.

Zoznam použitých zdrojov

Buck, T. a Ghiglione, D. (2020). European countries search for ventilators as virus cases surge. *Financial Times*. Dostupné online: <https://www.ft.com/content/5a2ffc78-6550-11ea-b3f3-fe4680ea68b5>

ECDC (2020) European Centre for Disease Prevention and Control: Dataset. Dostupné online: <https://www.ecdc.europa.eu/en/publications-data/download-todays-data-geographic-distribution-covid-19-cases-worldwide>

Ferguson, N., Laydon, D., Nedjati-Gilani, G. Imai, N. et al. (2020). Impact of non-pharmaceutical interventions (NPIs) to reduce COVID19 mortality and healthcare demand. Imperial College COVID-19 Response Team. Dostupné online: <https://www.imperial.ac.uk/media/imperial-college/medicine/sph/ide/gida-fellowships/Imperial-College-COVID19-NPI-modelling-16-03-2020.pdf>

Kucharski, A., Russel, W.T., Diamond, CH. et al. (2020) Early dynamics of transmission and control of COVID-19: a mathematical modelling study. *Lancet Infect Dis*. [https://doi.org/10.1016/S1473-3099\(20\)30144-4](https://doi.org/10.1016/S1473-3099(20)30144-4)

Li Q, Guan X, Wu P, Wang X, Zhou L, Tong Y, et al. (2020). "Early Transmission Dynamics in Wuhan, China, of Novel Coronavirus-Infected Pneumonia". *The New England Journal of Medicine*. doi:10.1056/NEJMoa2001316

Liu T., Gayle, A.A., Wilder-Smith, A a Rocklov, J. (2020) The reproductive number of COVID-19 is higher compared to SARS coronavirus. *Journal of Travel Medicine*. <https://doi.org/10.1093/jtm/taaa021>

Liu T, Hu J, Kang M, Lin L (2020a). "Time-varying transmission dynamics of Novel Coronavirus Pneumonia in China". *bioRxiv*. doi:10.1101/2020.01.25.919787.

Niehus, R., De Salazar, P. M., Taylor, A., & Lipsitch, M. (2020). Quantifying bias of COVID-19 prevalence and severity estimates in Wuhan, China that depend on reported cases in international travelers. *medRxiv*. doi: 10.1101/2020.02.13.20022707

Read, J. M., Bridgen, J. R., Cummings, D. A., Ho, A., & Jewell, C. P. (2020). Novel coronavirus 2019-nCoV: early estimation of epidemiological parameters and epidemic predictions. *medRxiv*. doi: 10.1101/2020.01.23.20018549.

Rocklov, J., Sjoding, H a Wilder-Smith, A. (2020) COVID-19 outbreak on the Diamond Princess cruise ship: estimating the epidemic potential and effectiveness of public health countermeasures. *Journal of Travel Medicine*, <https://doi.org/10.1093/jtm/taaa030>

Riou, J. and Althaus, Ch. L. (2020). "Pattern of early human-to-human transmission of Wuhan 2019 novel coronavirus (2019-nCoV), December 2019 to January 2020". *Eurosurveillance*. **25** (4). doi:10.2807/1560-7917.ES.2020.25.4.2000058

Verity R, Okell LC, Dorigatti I, et al. (2020) Estimates of the severity of COVID-19 disease. *medRxiv*; doi:10.1101/2020.03.09.20033357v1.

Wang, C. J., Ng, C. Y., & Brook, R. H. (2020). Response to COVID-19 in Taiwan: Big Data Analytics, New Technology, and Proactive Testing. *JAMA journal*, doi:10.1001/jama.2020.3151

Wesolowski, A., zu Erbach-Schoenberg, E., Tatem, A.J. et al. (2017) Multinational patterns of seasonal asymmetry in human movement influence infectious disease dynamics. *Nature Communications* **8**(2069) <https://doi.org/10.1038/s41467-017-02064-4>

Yeghikyan, G (2020) „Modelling the coronavirus epidemic in a city with Python“. *Towards data science*. Dosutpné online: <https://towardsdatascience.com/modelling-the-coronavirus-epidemic-spreading-in-a-city-with-python-babd14d82fa2>

Zhang, S., Diao, M., Yu, W., Pei, L., Lin, Z., & Chen, D. (2020). Estimation of the reproductive number of Novel Coronavirus (COVID-19) and the probable outbreak size on the Diamond Princess cruise ship: A data-driven analysis. *International Journal of Infectious Diseases*. doi: 10.1016/j.ijid.2020.02.033

Stephen A. Lauer, Kyra H. Grantz, Qifang Bi, Forrest K. Jones, Qulu Zheng, Hannah R. Meredith, Andrew S. Azman, Nicholas G. Reich, Justin Lessler. *The Incubation Period of Coronavirus Disease 2019 (COVID-19) From Publicly Reported Confirmed Cases: Estimation and Application. Annals of Internal Medicine*, 2020; DOI: 10.7326/M20-0504